PORTOFOLIO SERTIFIKASI ILMUWAN DATA (DATA SCIENTIST)

Prediksi Arah Harian IHSG

Berbasis Indikator Pasar Global dan Domestik, 2010 – 2026

Data nyata · 11 unit kompetensi SKKNI No. 299 Tahun 2020 · CRISP-DM

M. Syamsuddin Wisnubroto

Institut Teknologi Sumatera (ITERA)

Skema DSS.01.00.23 · LSP Digital Kreatif Solusi · Oktober 2026

Ringkasan proyek

Pertanyaan bisnis: apakah informasi pasar yang tersedia sebelum BEI dibuka dapat memperkirakan apakah IHSG ditutup naik pada hari bursa berikutnya?

- Data nyata harian **1 Jan 2010 – 29 Mei 2026**: IHSG, S&P 500, VIX, minyak, emas, USD/IDR, suku bunga BI & AS, inflasi (4.277 baris).
- **Klasifikasi biner** Naik vs Turun/Tetap, hanya memakai data yang sudah terbit sebelum 09.00 WIB.
- **Validasi deret waktu** (TimeSeriesSplit, purging, uji point-in-time) — tanpa pengacakan.
- Data uji **787 hari bursa (Jan 2023 – Mei 2026)** dipakai satu kali, setelah model final dipilih.

Keputusan review

Belum lanjut ke pilot: model mengalahkan baseline naif, tetapi setara dengan aturan sederhana "ikuti arah S&P 500" dan ROC-AUC belum mencapai target. Hasil dilaporkan apa adanya.

ACCURACY

0,560

LULUS

target ≥ 0,55

F1-MACRO

0,558

LULUS

target ≥ 0,55

ROC-AUC

0,569

TIDAK LULUS

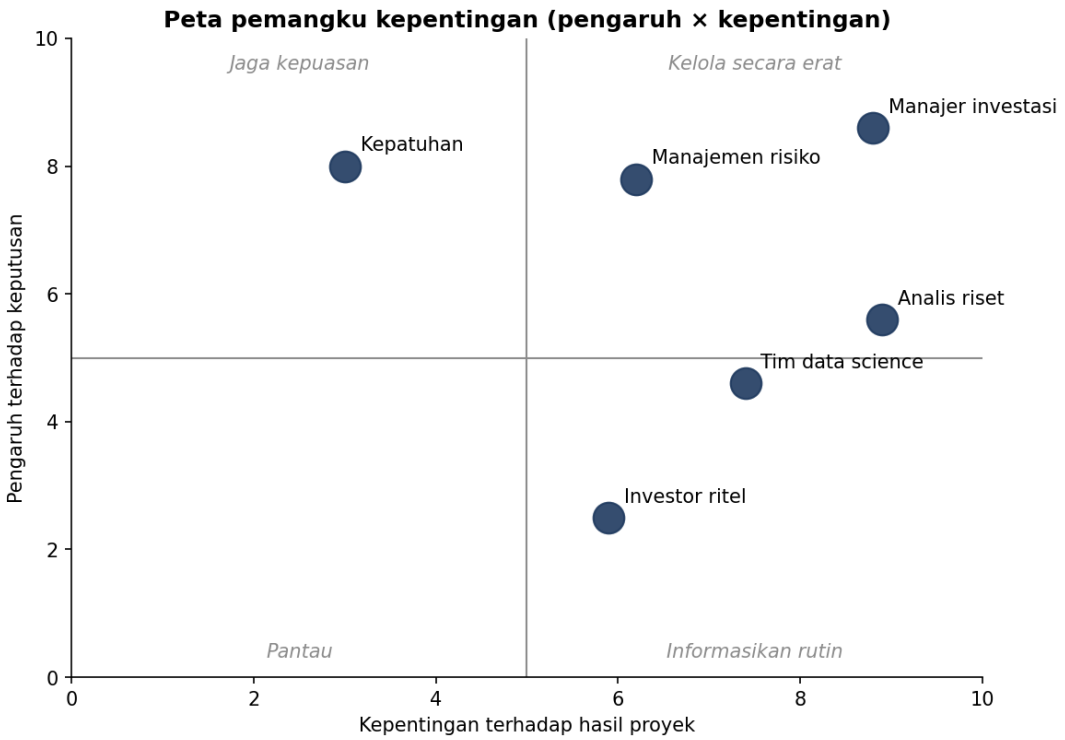
target ≥ 0,58

Model final: Random Forest · data uji 2023-01-25 s.d. 2026-05-26

11 unit kompetensi → notebook → bukti

No	Kode unit	Unit kompetensi	Notebook	Bukti utama
1	J.62DMI00.001.1	Menentukan Objektif Bisnis	01_*.ipynb	Pemangku kepentingan, kriteria sukses bisnis B1–B4
2	J.62DMI00.002.1	Menentukan Tujuan Teknis Data Science	02_*.ipynb	Definisi target, KPI T1–T5 ditetapkan sebelum pemodelan
3	J.62DMI00.005.1	Menelaah Data	03_*.ipynb	Frekuensi pembaruan, distribusi return, korelasi lead–lag
4	J.62DMI00.006.1	Memvalidasi Data	04_*.ipynb	Kartu skor 6 dimensi; log 339 anomali
5	J.62DMI00.007.1	Menentukan Objek Data	05_*.ipynb	Unit analisis, seleksi atribut, uji chi-kuadrat
6	J.62DMI00.008.1	Membersihkan Data	06_*.ipynb	6 langkah, 3.464 sel dikoreksi, 7 uji lulus
7	J.62DMI00.009.1	Mengkonstruksi Data	07_*.ipynb	16 fitur, split kronologis + purging, uji point-in-time
8	J.62DMI00.012.1	Membangun Skenario Model	08_*.ipynb	TimeSeriesSplit, 3 baseline + 5 algoritma
9	J.62DMI00.013.1	Membangun Model	09_*.ipynb	Validasi silang, grid search, diagnosis overfitting
10	J.62DMI00.014.1	Mengevaluasi Hasil Pemodelan	10_*.ipynb	KPI vs baseline, ROC, permutation importance
11	J.62DMI00.015.1	Melakukan Proses Review Pemodelan	11_*.ipynb	Drift (PSI), keterbatasan, rencana penerapan

Objektif bisnis: dukungan keputusan harian

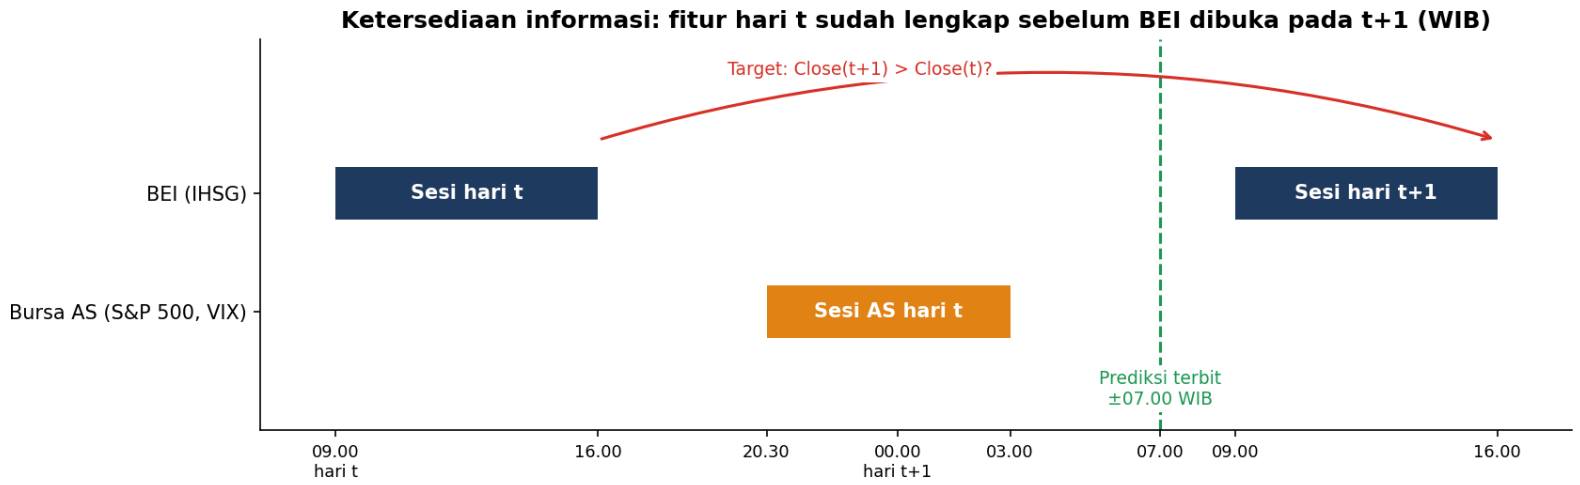


Enam pemangku kepentingan dipetakan menurut pengaruh dan kepentingan; risiko utama (sinyal lemah, perubahan rezim, look-ahead bias, kualitas data publik) disertai mitigasi.

- **Tujuan 1 —** probabilitas IHSG naik pada hari bursa berikutnya, terbit sebelum 09.00 WIB untuk morning brief.
- **Tujuan 2 —** peringkat faktor global/domestik yang paling berpengaruh.
- **Tujuan 3 —** peringatan dini hari dengan peluang turun tinggi untuk manajemen risiko.
- **Di luar cakupan:** sistem trading otomatis dan rekomendasi investasi.

Kode	Kriteria sukses bisnis
B1	Lebih informatif daripada aturan naif
B2	Faktor pendorong dapat dijelaskan
B3	Otomatis sebelum 08.30 WIB dari data publik
B4	Keterbatasan dilaporkan secara jujur

Tujuan teknis: klasifikasi biner tanpa kebocoran waktu

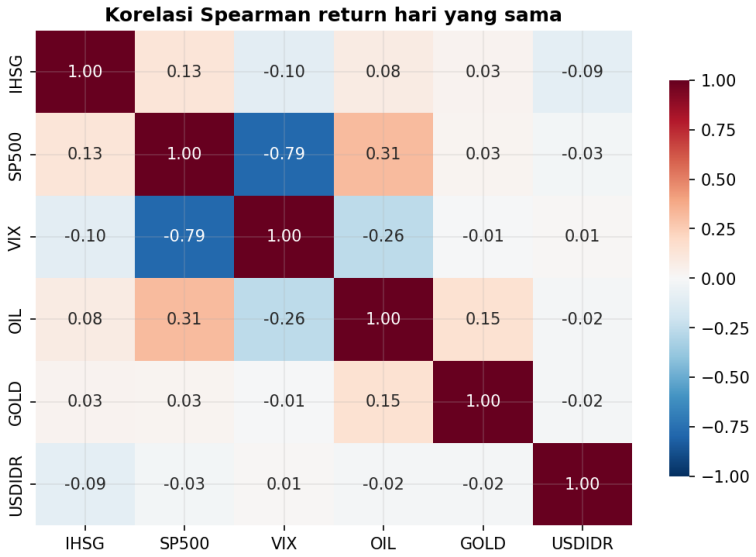


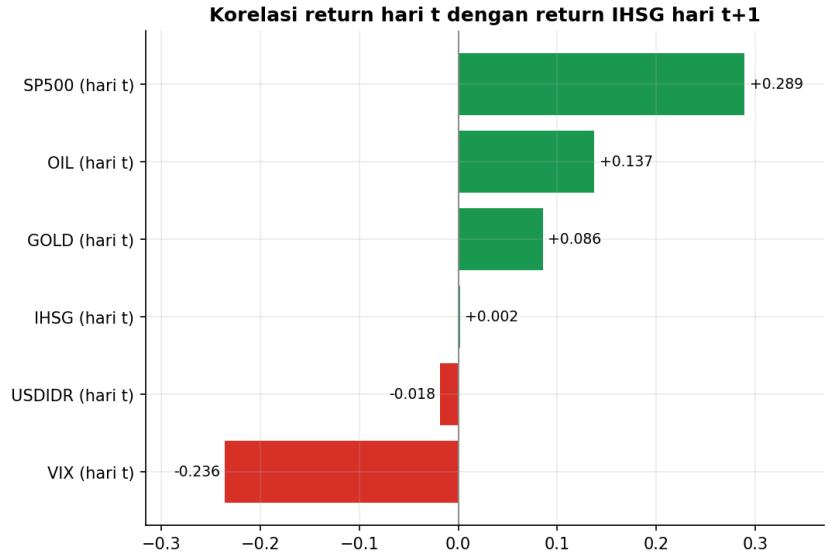
* Jam sesi AS mengikuti waktu musim panas AS; pada Nov–Mar sesi AS berlangsung ±21.30–04.00 WIB.

Kode	Kriteria teknis (data uji)	Ambang
T1	Accuracy	≥ 0,55
T2	F1-macro	≥ 0,55
T3	ROC-AUC	≥ 0,58
T4	Mengalahkan baseline mayoritas & acak	semua metrik
T5	Tanpa kebocoran data	uji PIT + purging

- **Target:** y = 1 jika Close IHSG(t+1) > Close IHSG(t).
- **Validasi:** holdout kronologis 80/20 + TimeSeriesSplit 5 lipatan di data latih.
- **Ambang realistis:** akurasi > 0,70 untuk arah harian justru patut dicurigai sebagai kebocoran.

Telaah data: limpahan sesi AS adalah sinyal terkuat





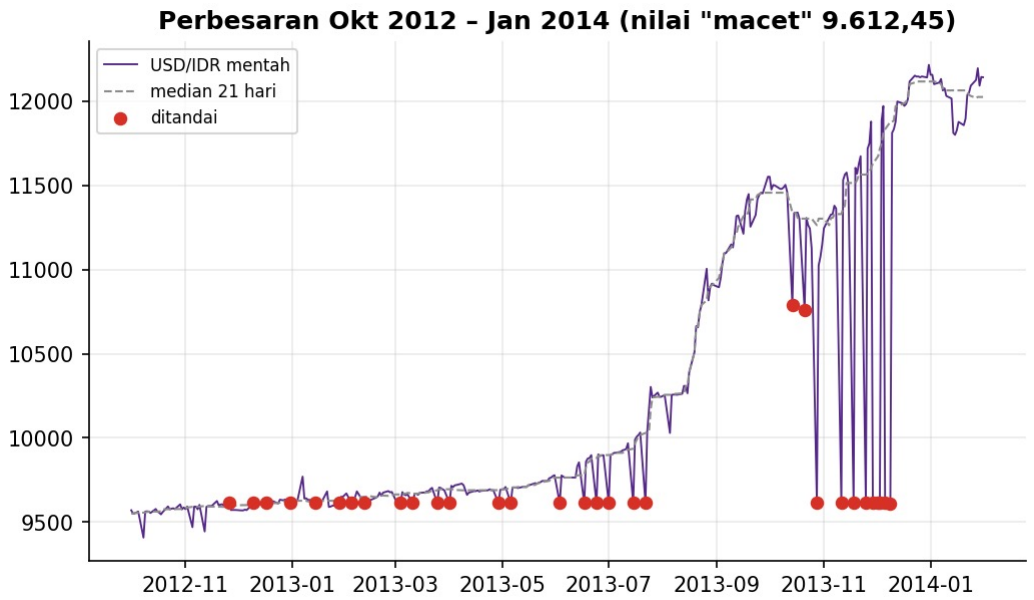
- 4.277 baris hari kerja; **3.976 hari bursa BEI.**
- **Frekuensi teramati:** 6 variabel harian, US_rate bulanan, CPI tahunan, BI_rate campuran.
- **Return IHSG berekor tebal:** hari > 3σ ≈ 6× lebih sering daripada distribusi normal.
- **Korelasi diukur pada return** (bukan level) dengan Spearman, hanya periode 2010–2022.

Temuan kunci

Return S&P 500 hari t berkorelasi +0,29 dengan return IHSG hari t+1, jauh lebih kuat daripada korelasi pada hari yang sama (+0,13). Sesi AS berlangsung setelah BEI tutup, sehingga informasinya baru tercermin keesokan hari.

Validasi data: empat isu nyata ditemukan dan dicatat



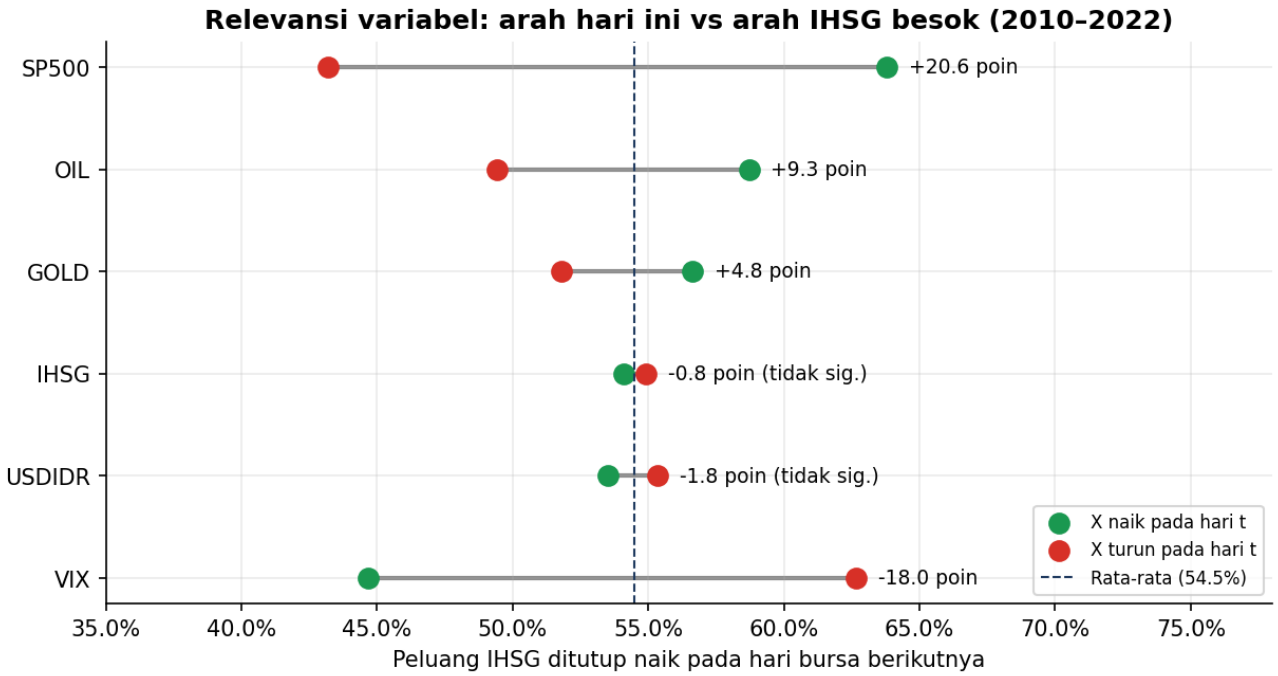


Isu	Jumlah	Tindakan
Kutipan USD/IDR rusak (3 aturan deteksi)	37	Forward-fill (Unit 6)
Harga minyak negatif 20 Apr 2020 (peristiwa nyata)	1	Forward-fill + winsorization
Hari libur BEI: IHSG disalin dari hari sebelumnya	300	Hapus dari unit analisis
Look-ahead: CPI tahunan sejak 1 Jan; suku bunga sejak awal bulan	3 variabel	CPI keluar; suku bunga akhir bulan lalu

Kontrol metode

Lonjakan nyata rupiah ke ±16.500 saat krisis COVID-19 (24 Mar 2020) tidak ikut tertandai. Nilai "macet" 9.612,45 muncul pada 28 tanggal terpisah.

Objek data: unit analisis, target, dan seleksi atribut

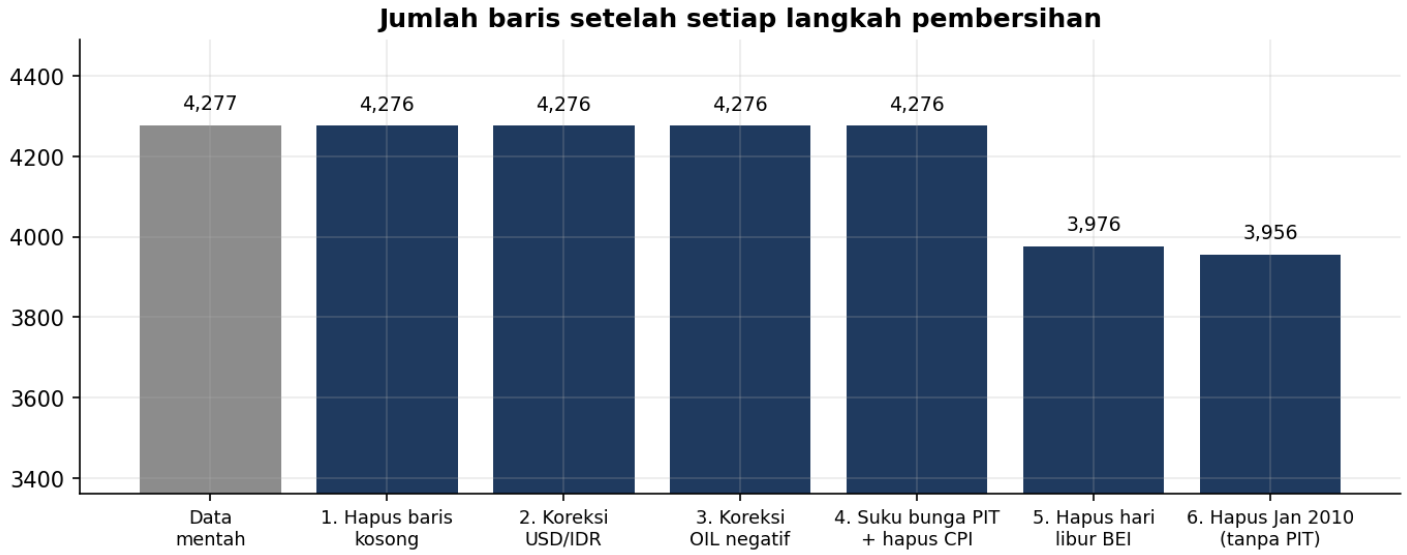


- **Unit analisis:** satu hari bursa BEI; t+1 = hari bursa berikutnya.
- **Record:** 4.277 → 3.975 setelah seleksi.
- **CPI dikeluarkan:** look-ahead bias dan hanya 17 nilai unik (penanda tahun).
- **Level harga diganti return/rasio** karena tidak stasioner.
- **16 fitur direncanakan** di reports/feature_plan.csv.

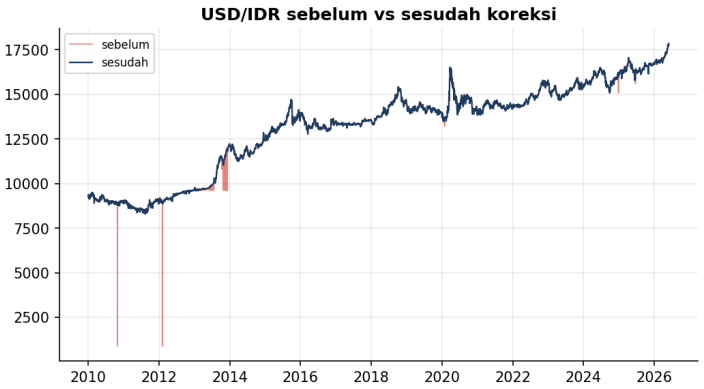
Uji relevansi (chi-kuadrat, 2010–2022)

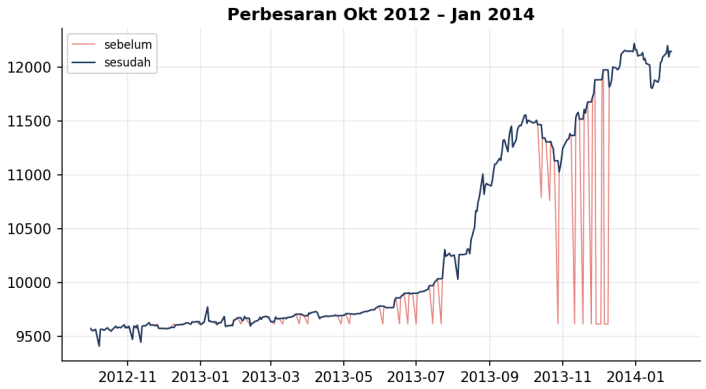
Peluang IHSG naik besok 63,8% bila S&P 500 naik vs 43,2% bila turun (selisih +20,6 poin); VIX −18,0 poin; minyak +9,3 poin; emas +4,8 poin — semuanya signifikan. Arah hubungan S&P 500 dan VIX konsisten di 13 dari 13 tahun.

Pembersihan data: enam langkah, terverifikasi otomatis



Uji verifikasi	Hasil
Tidak ada nilai kosong	LULUS
Tanggal unik & berurutan	LULUS
Semua harga > 0	LULUS
Tidak ada hari IHSG "tidak berubah"	LULUS
USD/IDR ≤ 4% dari median 21 hari	LULUS
CPI sudah dikeluarkan	LULUS
Suku bunga PIT tidak mendahului data	LULUS





Forward-fill, bukan interpolasi: interpolasi akan "mengintip" nilai hari berikutnya.

Hasil: 3.956 hari bursa bersih; 3.464 sel dikoreksi.

Sempat gagal satu uji (USD/IDR 19 Jun 2025) → aturan deteksi diperbaiki di Unit 4.

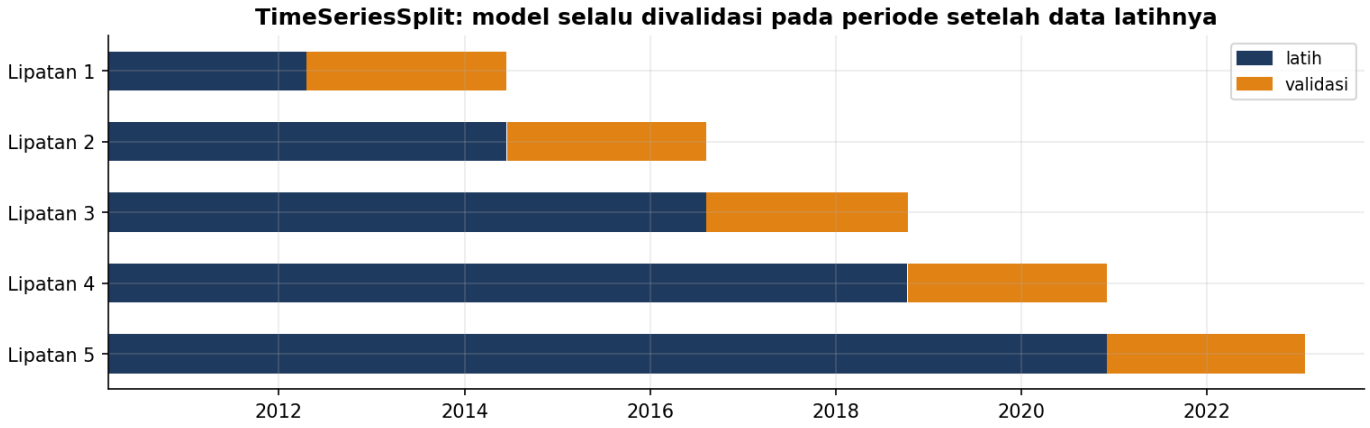
Konstruksi data: 16 fitur, split kronologis, uji kebocoran



Kelompok	Fitur
IHSG (8)	return t, t-1..t-3, momentum 5 hari, jarak ke MA5/MA20, volatilitas 10 hari
Pasar AS (4)	return S&P 500 t & t-1, level VIX, perubahan VIX
Komoditas & kurs (3)	return minyak, emas, USD/IDR
Kebijakan moneter (1)	BI rate − Fed rate (nilai akhir bulan sebelumnya)

- **Latih:** 3.148 hari (Mar 2010 – Jan 2023)
- **Uji:** 787 hari (Jan 2023 – Mei 2026)
- **Purging 1 hari** agar label tidak tumpang tindih.
- **Uji point-in-time:** 40 tanggal, 0 selisih; kontrol negatif tertangkap.
- **Winsorization 1–99%** dari data latih saja.

Skenario model: validasi yang menghormati urutan waktu

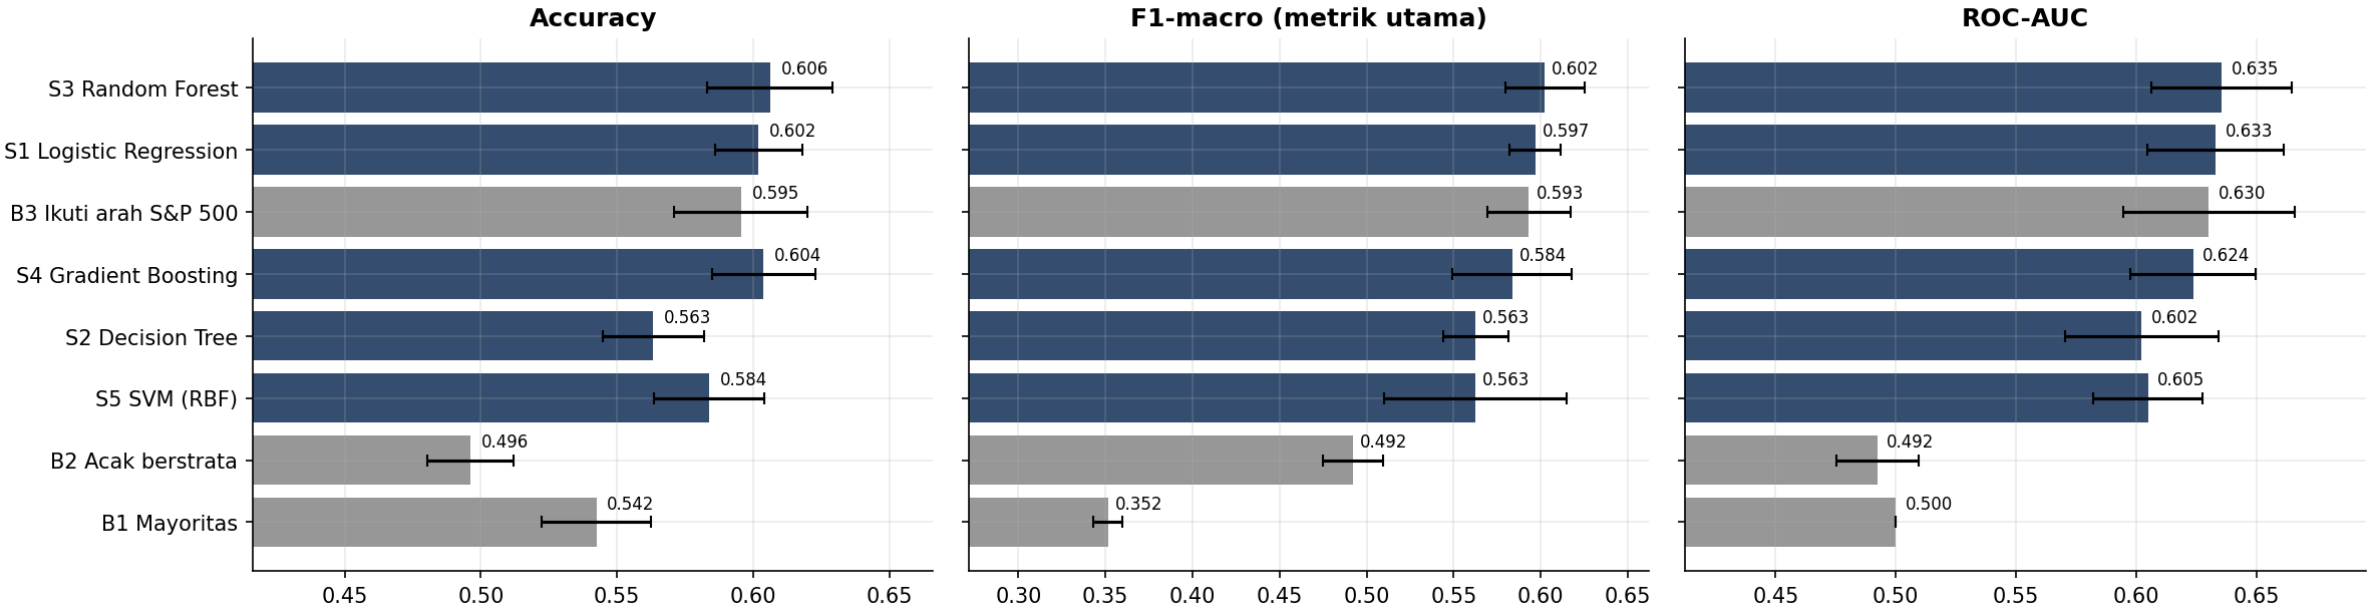


- **TimeSeriesSplit 5 lipatan, gap 1 hari:** model selalu diuji pada periode setelah data latihnya.
- **Metrik utama F1-macro** (adil untuk kedua kelas), lalu ROC-AUC.
- **Standardisasi di dalam Pipeline** sehingga di-fit ulang per lipatan.
- **Aturan pemilihan ditulis sebelum eksperimen** dan disimpan di model_scenarios.json.

ID	Skenario	Catatan
B1	Mayoritas	selalu menebak kelas terbanyak
B2	Acak berstrata	sesuai proporsi kelas
B3	Ikuti arah S&P 500	baseline domain yang kuat
S1	Logistic Regression	standardisasi, balanced
S2	Decision Tree	max_depth 4, min leaf 50
S3	Random Forest	300 pohon, max_depth 5
S4	Gradient Boosting	150 pohon, lr 0,05
S5	SVM (RBF)	standardisasi, balanced

Membangun model: Random Forest terpilih

Validasi silang TimeSeriesSplit (rata-rata ± simpangan baku 5 lipatan; abu-abu = baseline)



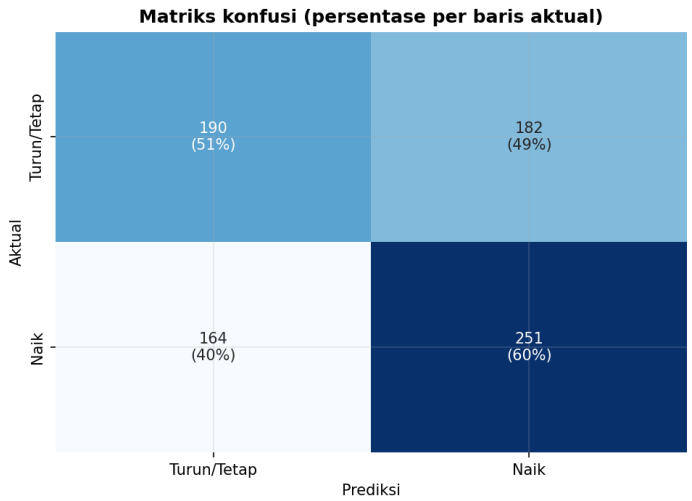
Pemilihan & tuning — tipis di atas baseline

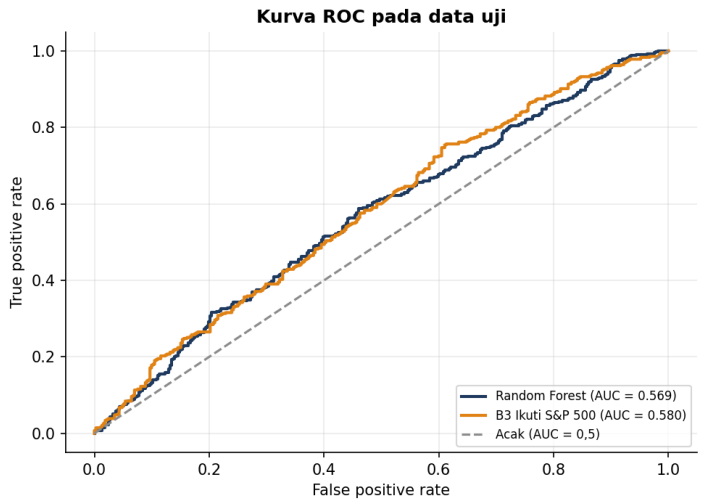
S3 Random Forest: F1-macro CV 0,602 vs B3 0,593. Grid search 9 kombinasi → max_depth 8, min_samples_leaf 20 (F1 CV 0,603).

Diagnosis overfitting

F1 data latih 0,726 vs CV 0,603 (selisih 0,123 ≥ 0,10) → ditandai dan dibahas di review.

Evaluasi pada data uji: 4 dari 5 kriteria terpenuhi





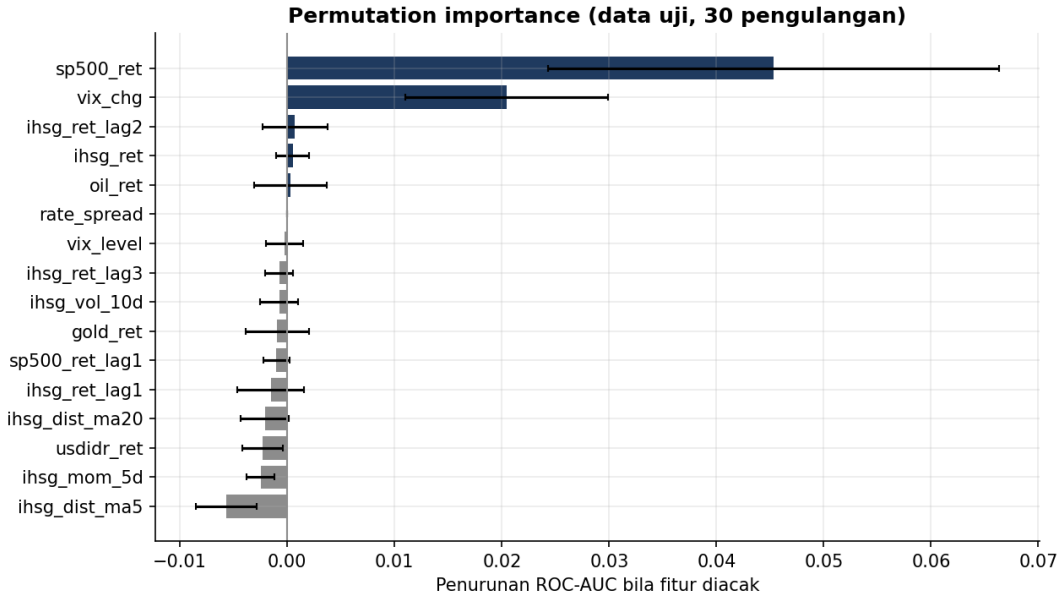
Model / baseline	Accuracy	F1-macro	ROC-AUC
Random Forest (final)	**0,560**	**0,558**	**0,569**
B3 Ikuti S&P 500	0,553	0,550	0,580
B2 Acak berstrata	0,513	0,510	0,511
B1 Mayoritas	0,527	0,345	0,500

Kriteria	Nilai	Status
T1 Accuracy ≥ 0,55	0,560	LULUS
T2 F1-macro ≥ 0,55	0,558	LULUS
T3 ROC-AUC ≥ 0,58	0,569	TIDAK LULUS
T4 Kalahkan B1 & B2	–	LULUS
T5 Tanpa kebocoran	–	LULUS

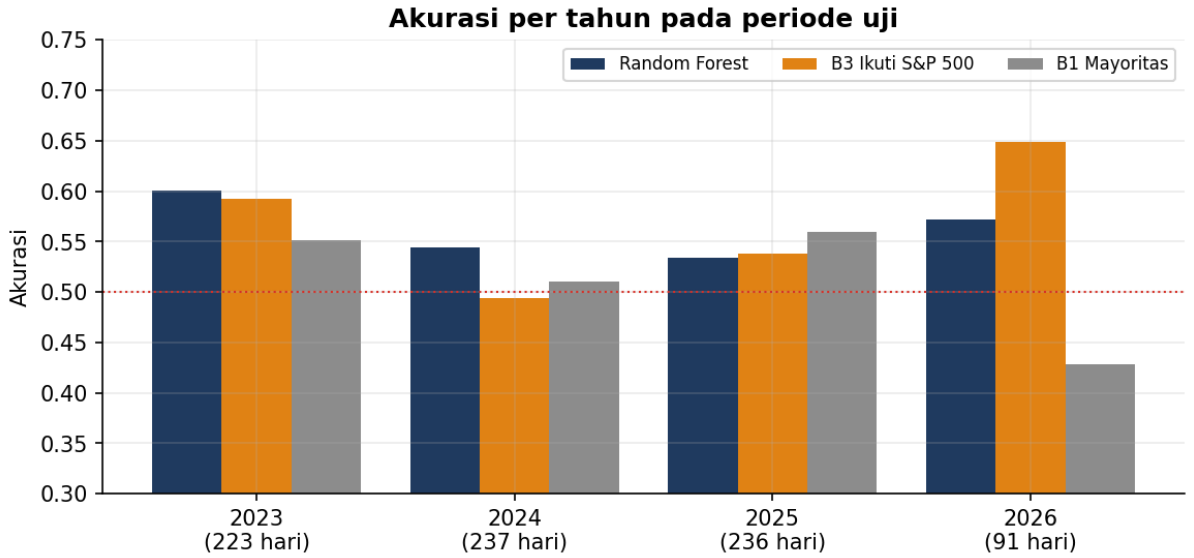
Interpretasi jujur

Model mengalahkan baseline naif, tetapi selisihnya terhadap aturan "ikuti S&P 500" hanya +0,8 poin akurasi dan −0,011 AUC. ROC-AUC 0,569 belum mencapai ambang 0,58. Model tidak disetel ulang setelah melihat data uji.

Faktor pendorong, keyakinan, dan stabilitas per tahun

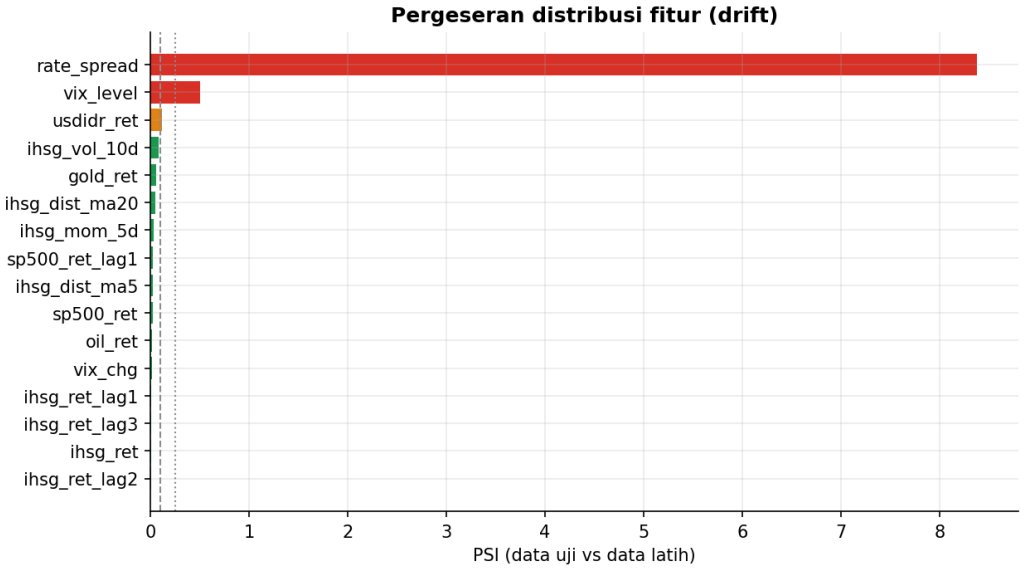


Permutation importance: penurunan ROC-AUC data uji bila nilai satu fitur diacak 30 kali. Berlaku untuk semua jenis model dan dihitung pada data yang belum pernah dilihat.



- **Faktor utama:** return S&P 500 dan perubahan VIX; fitur lain hampir tidak berkontribusi.
- **Sepertiga prediksi paling yakin:** akurasi 58,6%.
- **Akurasi per tahun:** 53,4% – 60,1%.
- **Makna ekonomi:** hari diprediksi naik rata-rata +0,14% vs −0,19% ($p < 0{,}001$) — kualitas informasi, bukan keuntungan trading.

Review pemodelan: keterbatasan yang terukur



Keterbatasan	Bukti
Sinyal terkonsentrasi	S&P 500 fitur terpenting; ΔAUC vs B3 −0,011
Bukan strategi trading	Info sesi AS sudah tercermin di harga pembukaan BEI
Pergeseran rezim	rate_spread uji 0,42–1,52 vs latih 1,40–7,64 (PSI 8,4)
Tuning kurang hemat	max_depth 8 untuk +0,0008 F1; selisih latih–CV 0,123
Kualitas & cakupan data	Satu sumber; tanpa data intrahari dan aliran dana asing

Integritas evaluasi

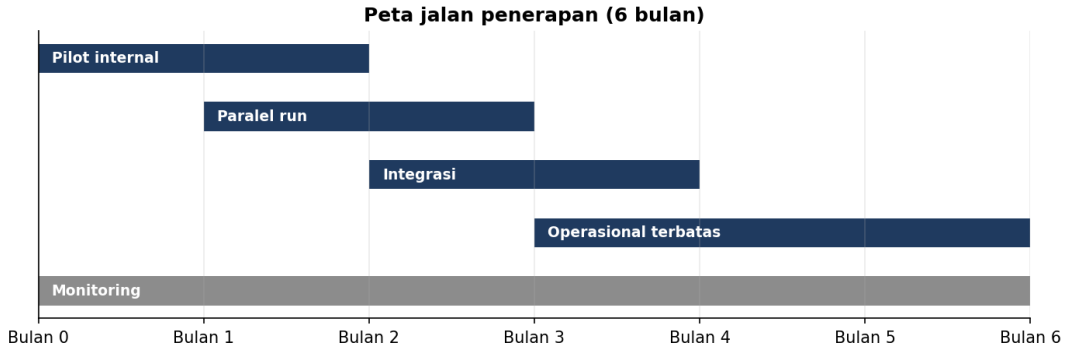
Data uji Jan 2023 – Mei 2026 sudah dipakai satu kali. Perbaikan berikutnya tidak boleh dinilai ulang dengan data yang sama — siklus berikutnya dievaluasi dengan data baru setelah Mei 2026 atau melalui paralel run pada fase pilot. Semua angka di notebook review dibaca dari artefak tahap sebelumnya, bukan diketik ulang.

Keputusan dan rekomendasi

Keputusan: BELUM LANJUT ke pilot

Kriteria T3 (ROC-AUC ≥ 0,58) belum terpenuhi dan nilai tambah terhadap aturan "ikuti S&P 500" belum terbukti. Jalankan rekomendasi prioritas tinggi, lalu ulangi siklus pemodelan.

Prioritas	Rekomendasi
Tinggi	Aturan parsimoni saat tuning (one-standard-error rule)
Tinggi	Ganti rate_spread (level) dengan perubahan/arah kebijakan suku bunga
Tinggi	Backtest dengan harga pembukaan BEI dan biaya transaksi
Tinggi	Fitur pasar Asia yang buka sebelum BEI + futures S&P 500 pagi hari
Tinggi	Walk-forward retraining bulanan
Sedang	Kalibrasi probabilitas dan zona keyakinan; data aliran dana asing harian



- **Monitoring:** akurasi & AUC bergulir 60 hari, PSI fitur bulanan, cek kualitas data harian.
- **Pemicu:** model kalah dari "ikuti S&P 500" 3 bulan → evaluasi ulang nilai tambah.

Terima kasih

Pelajaran utama: pada data keuangan nyata, kerja terpenting ada pada validasi data, pencegahan kebocoran waktu, dan evaluasi yang jujur terhadap baseline yang kuat.

Repositori: portfolio-ilmuwan-data — 11 notebook, ekspor HTML, 24 grafik, artefak JSON/CSV

M. Syamsuddin Wisnubroto · ITERA · syamsuddin.wisnubroto@sd.itera.ac.id

Proyek ini adalah portofolio kompetensi dan bukan rekomendasi investasi.